Лекция 8

Интервальные оценки неизвестных параметров распределений

Пусть $\{X_1, \dots, X_n\}$ — выборка, порожденная СВ X, закон распределения которой зависит от неизвестного параметра θ. Пусть $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ и $\hat{\hat{\theta}} = \hat{\hat{\theta}}(X_1, \dots, X_n)$ — некоторые статистики. Промежуток $(\hat{\theta}, \hat{\hat{\theta}})$ называется γ-доверительным интервалом для параметра θ, если при любом допустимом значении θ

$$P\{\hat{\theta} < \theta < \hat{\hat{\theta}}\} = \gamma;$$

число γ при этом называется доверительной вероятностью (или надёжностью) оценки $\hat{\theta} < \theta < \hat{\hat{\theta}}$.

При этом говорят также, что интервал $(\hat{\theta}, \hat{\hat{\theta}})$ накрывает неизвестный параметр θ с вероятностью γ. Ясно, что оценка $\hat{\theta} < \theta < \hat{\hat{\theta}}$ тем лучше и точнее, чем ~~бо~~ ближе γ к 1 и чем меньше разность $\hat{\hat{\theta}} - \hat{\theta}$.

Отметим, что середину $\theta^* = \frac{\hat{\theta} + \hat{\hat{\theta}}}{2}$ интервала $(\hat{\theta}, \hat{\hat{\theta}})$ можно рассматривать как точечную оценку для θ, при этом погрешность приближения $\theta \approx \theta^*$

с вероятностью γ не будет превосходить величины $\frac{1}{2}(\hat{\hat{\theta}}-\hat{\theta})$, которую называют точностью оценки.

Опишем один из методов нахождения интервальных оценок. Рассмотрим некоторую статистику

$$Y = g(X_1, \dots, X_n; \theta),$$

определяемую выборкой $X_1, \dots, X_n$ и неизвестным параметром θ, от которого зависит распределение СВ X. Предположим, что

а) закон распределения СВ Y не зависит от θ,

б) для каждой реализации $x_1, \dots, x_n$ выборки $X_1, \dots, X_n$ детерминированная функция $g(x_1, \dots, x_n; \theta)$ является строго монотонной по θ (пусть строго возрастающей для определенности)

В этом случае для любых реализаций случайных величин $\hat{\theta}$ и $\hat{\hat{\theta}}$ неравенство

$$\hat{\theta} < \theta < \hat{\hat{\theta}}$$

будет эквивалентно неравенству $g(x_1, \dots, x_n; \hat{\theta}) < g(x_1, \dots, x_n; \theta) < g(x_1, \dots, x_n; \hat{\hat{\theta}})$, вследствие чего вероятность

$$\gamma = P\{\hat{\theta} < \theta < \hat{\hat{\theta}}\}$$

совпадёт с вероятностью

$$\gamma = P\{\hat{Y} < Y < \hat{\hat{Y}}\},$$

которая (см. пункт а)) не будет зависеть от неизвестного значения параметра θ; здесь $\hat{Y} = g(X_1, \dots, X_n, \hat{\theta})$, $\hat{\hat{Y}} = g(X_1, \dots, X_n, \hat{\hat{\theta}})$.

<u>Пример</u> Пусть выборка $\{X_1, \dots, X_n\}$ порождена СВ X, имеющей нормальное распределение с неизвестным математическим ожиданием θ и известной дисперсией σ^2. Построить интервальные оценки для θ.

Решение. Рассмотрим СВ

$$\overline{X}_n = \frac{X_1 + \dots + X_n}{n};$$

Она имеет нормальное распределение с малым ожиданием

$$M\{\overline{X}_n\} = \frac{1}{n}(MX_1 + \dots + MX_n) = MX = \theta$$

и дисперсией

$$D\{\overline{X}_n\} = \frac{1}{n^2}(DX_1 + \dots + DX_n) = \frac{DX}{n} = \frac{\sigma^2}{n}.$$

Значит, СВ

$$\frac{\overline{X}_n - \theta}{\sqrt{\frac{\sigma^2}{n}}} = \frac{\overline{X}_n - \theta}{\sigma} \cdot n^{1/2}$$

имеет нормальное распределение с нулевым математическим ожиданием и единичной дисперсией, т.е. распределение этой СВ не зависит от θ. Положим $Y = \frac{\overline{X}_n - \theta}{\sigma} \cdot n^{1/2}$.

Тогда для любых чисел $\hat{y}$ и $\hat{\hat{y}} > \hat{y}$

$$P\{\hat{y} < Y < \hat{\hat{y}}\} = \int_{\hat{y}}^{\hat{\hat{y}}} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy = \Phi(\hat{\hat{y}}) - \Phi(\hat{y}),$$

где $\Phi(z) = \int_0^z \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$ — функция Лапласа.

Обозначим $\Phi(\hat{\hat{y}}) - \Phi(\hat{y}) = \gamma$. Тогда

$$P\left\{\hat{y} < \frac{\overline{X}_n - \theta}{\sigma} \cdot n^{1/2} < \hat{\hat{y}}\right\} = \gamma \qquad (*)$$

Возьмём для определенности $\hat{\hat{y}} = \Delta$, $\hat{y} = -\Delta$, где $\Delta > 0$. Тогда

$$P\left\{-\Delta < \frac{\overline{X}_n - \theta}{\sigma} \cdot n^{1/2} < \Delta\right\} = \gamma, \quad \gamma = 2\Phi(\Delta),$$

$$P\left\{-\frac{\Delta\sigma}{\sqrt{n}} < \overline{X}_n - \theta < \frac{\Delta\sigma}{\sqrt{n}}\right\} = \gamma,$$

$$P\left\{\frac{\Delta\sigma}{\sqrt{n}} > \theta - \overline{X}_n > -\frac{\Delta\sigma}{\sqrt{n}}\right\} = \gamma,$$

$$P\left\{\overline{X}_n - \frac{\Delta\sigma}{\sqrt{n}} < \theta < \overline{X}_n + \frac{\Delta\sigma}{\sqrt{n}}\right\} = \gamma.$$

Последнее равенство и решает проблему. Здесь:

$$\hat{\theta} = \overline{X}_n - \frac{\Delta\sigma}{\sqrt{n}}, \quad \hat{\hat{\theta}} = \overline{X}_n + \frac{\Delta\sigma}{\sqrt{n}}$$

— искомые статистики (см. начало лекции). При этом, разумеется, параметры γ (доверительная вероятность) и Δ (параметр, определяющий доверительный

интервал) связаны друг с другом: если мы хотим „загнать" неизвестный параметр θ в какой-либо интервал с вероятностью γ, близкой к 1, то этот интервал не будет маленьким — с увеличением γ длина интервала $\left(\overline{X}_n - \frac{\Delta\sigma}{\sqrt{n}}, \overline{X}_n + \frac{\Delta\sigma}{\sqrt{n}}\right)$ возрастает: γ и Δ связаны равенством $\gamma = 2\Phi(\Delta)$.

<u>Замечание</u> (по поводу выбора значений $\hat{\gamma}$ и $\hat{\hat{\gamma}}$ при фиксированном γ в формуле (*))

Перепишем (*) в виде:

$$P\left\{\underbrace{\overline{X}_n - \frac{\hat{\gamma}\sigma}{\sqrt{n}}}_{\hat{\theta}} < \theta < \underbrace{\overline{X}_n - \frac{\hat{\hat{\gamma}}\sigma}{\sqrt{n}}}_{\hat{\hat{\theta}}}\right\} = \gamma.$$

Ясно, что при фиксированном значении γ значение $\hat{\gamma}$ и $\hat{\hat{\gamma}}$ выбираются неоднозначно. В частности, устремляя $\hat{\hat{\gamma}}$ к $+\infty$ или $\hat{\gamma}$ к $-\infty$, можно написать и односторонние оценки:

$$P\left\{\theta < \overline{X}_n - \frac{\hat{\gamma}\sigma}{\sqrt{n}}\right\} = \gamma \quad \text{или} \quad P\left\{\overline{X}_n - \frac{\hat{\hat{\gamma}}\sigma}{\sqrt{n}} < \theta\right\} = \gamma,$$

в которых значение $\hat{\gamma}$ и $\hat{\hat{\gamma}}$ определяются уже однозначно.

Как правило, используются двусторонние оценки

$$P\{\hat{\theta} < \theta < \hat{\hat{\theta}}\} = \gamma,$$

удовлетворяющие условию

$$P\{\theta < \hat{\theta}\} = P\{\theta > \hat{\hat{\theta}}\} = \frac{1-\gamma}{2}.$$

Такие оценки называют симметричными по вероятности. Именно такие оценки были использованы в приведённом выше примере.

Симметричные по вероятности доверительные оценки используются наиболее часто: они легко находятся, а соответствующий γ-доверительный интервал $(\hat{\theta}, \hat{\hat{\theta}})$ имеет, как правило, наименьшую длину среди прочих γ-доверительных интервалов, обеспечивая тем самым наилучшую точность оценки.

Распределение Стьюдента

Теорема (без док-ва) Пусть $X_1, \dots, X_n$ – независимые одинаково распределенные СВ, определяемые плотностью

$$f(x) = \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in (-\infty; +\infty).$$

Тогда случайная величина

$$T = \frac{\overline{X}_n - \mu}{S/\sqrt{n}}, \text{ где } \overline{X}_n = \frac{X_1 + \dots + X_n}{n},$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X}_n)^2,$$

имеет распределение Стьюдента с $(n-1)$ степенями свободы.

По определению, распределение Стьюдента с n степенями свободы определяется плотностью

$$s_n(t) = b_n\left(1+\frac{t^2}{n-1}\right)^{-\frac{n}{2}}, \quad t\in(-\infty;+\infty), \qquad (**)$$

где

$$b_n = \frac{\Gamma\left(\frac{n}{2}\right)}{\sqrt{\pi(n-1)}\,\Gamma\left(\frac{n-1}{2}\right)}.$$

Здесь $\Gamma(\alpha)$, $\alpha>0$, — гамма функция, вводимая интегралом

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1}e^{-x}dx.$$

Легко проверяются следующие свойства гамма функции.

1. $\Gamma(1)=1$.
2. $\Gamma(\alpha+1)=\alpha\Gamma(\alpha)$.
3. $\Gamma(n+1)=n!$ для любого $n=1,2,3,\ldots$
4. $\Gamma\left(\frac{1}{2}\right)=\sqrt{\pi}$,

так что, например, $\Gamma\left(\frac{5}{2}\right)=\Gamma\left(\frac{3}{2}+1\right)=$
$=\frac{3}{2}\Gamma\left(\frac{3}{2}\right)=\frac{3}{2}\Gamma\left(1+\frac{1}{2}\right)=\frac{3}{2}\cdot\frac{1}{2}\Gamma\left(\frac{1}{2}\right)=\frac{3}{4}\sqrt{\pi}$ и т.п.

Как следует из $(**)$, плотность $s_n(t)$ есть четная функция, монотонно возрастающая на $(-\infty,0]$ и монотонно убывающая на $[0,+\infty)$. При $n\geq 10$ плотность $s_n(t)$ мало отличается от плотности стандартного нормального распределения.