Лекция 10

Интервальные оценки неизвестной дисперсии нормального распределения при неизвестном мат. ожидании. Приближенные (асимптотические) доверительные интервалы.

Пусть выборка $\{X_1, \dots, X_n\}$ порождена СВ X, имеющей нормальное распределение с неизвестным математическим ожиданием a и неизвестной дисперсией $\theta = \sigma^2$. Найдём интервальные оценки для неизвестного параметра θ.

С этой целью рассмотрим статистику

$$Z = \frac{(n-1)\tilde{S}_n^2}{\sigma^2}, \text{ где } \underbrace{\tilde{S}_n^2}_{\text{исправленная выборочная дисперсия}} = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2,$$

$$\overline{X}_n = \frac{X_1 + \dots + X_n}{n} \text{ - выборочное среднее.}$$

<u>Теорема</u> (без док-ва) Если СВ $X_1, \dots, X_n$ независимы и распределены по нормальному закону с одинаковыми математическими ожиданиями и ~~дисп~~ одинаковыми дисперсиями σ^2, то СВ Z имеет распределение χ^2 с $(n-1)$ степенями свободы, т.е. плотность распределения СВ Z даётся формулой

$$f_{\chi^2(n-1)}(x) = \frac{1}{2^{\frac{n-1}{2}}\Gamma\left(\frac{n-1}{2}\right)} x^{\frac{n-1}{2}-1} e^{-\frac{x}{2}}, \quad x > 0,$$

где $\Gamma(\dots)$ – гамма функция.

(На стр. 5 лекции 9 выписана плотность распределения χ^2 с n степенями свободы, $\chi^2(n)$)

Введенная статистика Z удовлетворяет требованиям а) и б) на стр. 2 лекции 8 (такие статистики называются центральными) и можем быть использована для нахождения интервальных оценок для θ по той схеме, что была описана в лекции 8.

Пусть статистики $\hat{\theta}$ и $\hat{\hat{\theta}}$ таковы, что

$$P\{\hat{\theta} < \theta < \hat{\hat{\theta}}\} = \gamma ,$$

где γ – заданная доверительная вероятность. Выберем числа $\alpha > 0$ и $\beta > \alpha$ так, чтобы

$$P\left\{\alpha < \frac{(n-1)\tilde{S}_n^2}{\theta} < \beta\right\} = \gamma ,$$

или

$$P\left\{\frac{(n-1)\tilde{S}_n^2}{\beta} < \theta < \frac{(n-1)\tilde{S}_n^2}{\alpha}\right\} = \gamma .$$

Потребуем, чтобы интервальные оценки были симметричными по вероятности (см. лекцию 8), т.е. чтобы

$$P\left\{\theta < \frac{(n-1)\tilde{S}_n^2}{\beta}\right\} = P\left\{\theta > \frac{(n-1)\tilde{S}_n^2}{\alpha}\right\} = \frac{1-\gamma}{2}$$

Эти условия позволяют однозначно определить α и β:

$$P\left\{\theta < \frac{(n-1)\cdot\tilde{S}_n^2}{\beta}\right\} = \frac{1-\gamma}{2} \Leftrightarrow P\left\{\frac{(n-1)\tilde{S}_n^2}{\theta} > \beta\right\} = \frac{1-\gamma}{2}$$

$$\Longleftrightarrow \int_{\beta}^{+\infty} f_{\chi^2(n-1)}(x)\,dx = \frac{1-\gamma}{2} \Rightarrow$$ по таблицам распределения $\chi^2(n-1)$ определяем значение β.

$$P\left\{\theta > \frac{(n-1)\tilde{S}_n^2}{\alpha}\right\} = \frac{1-\gamma}{2} \Longleftrightarrow P\left\{\frac{(n-1)\tilde{S}_n^2}{\theta} < \alpha\right\} = \frac{1-\gamma}{2}$$

$$\Longleftrightarrow \int_{0}^{\alpha} f_{\chi^2(n-1)}(x)\,dx = \frac{1-\gamma}{2} \Rightarrow$$ по таблицам распределения $\chi^2(n-1)$ определяем значение α.

Терминологическое дополнение. Пусть $F(x)$ – функция распределения СВ X. Корень уравнения $F(x)=q$ называется квантилью уровня q (или q-квантилью) СВ X, или соответствующего распределения.

Таким образом,

$$\alpha = \left\{\begin{array}{l}\text{квантиль уровня } \frac{1-\gamma}{2} \\ \text{распределения } \chi^2 \text{ с} \\ (n-1) \text{ степенями свободы}\end{array}\right\},$$

$$\beta = \left\{\begin{array}{l}\text{квантиль уровня } 1-\frac{1-\gamma}{2} = \frac{1+\gamma}{2} \\ \text{распределения } \chi^2 \text{ с } (n-1) \text{ степенями свободы}\end{array}\right\}.$$

Пример 1. Изучается нормально распределенная СВ с неизвестными математическим ожиданием и дисперсией. По результатам 25 испытаний найдена исправленная выборочная дисперсия $\tilde{S}_{25}^2 = 0{,}35$. Найти симметричные по вероятности интервальные оценки, покрывающие неизвестную генерал-

нную дисперсию σ^2 с доверительной вероятностью $\gamma = 0,95$.

<u>Решение</u>. В соответствии с общими результатами имеем

$$P\left\{ \frac{(25-1)\cdot 0,35}{\beta} < \sigma^2 < \frac{(25-1)\cdot 0,35}{\alpha} \right\} = 0,95,$$

где

$$\alpha = \left\{ \begin{array}{l} \text{квантиль уровня } \frac{1-0,95}{2} = 0,025 \\ \text{распределения } \chi^2 \text{ с} \\ 25-1=24 \text{ степенями свободы} \end{array} \right\} = 12,401$$

определяем по таблицам распределения χ^2 с 24 степенями свободы

$$\beta = \left\{ \begin{array}{l} \text{квантиль уровня } \frac{1+0,95}{2} = 0,975 \\ \text{распределения } \chi^2 \text{ с } 25-1=24 \\ \text{степенями свободы} \end{array} \right\} = 39,364$$

Следовательно,

$$P\left\{ \frac{24\cdot 0,35}{39,364} < \sigma^2 < \frac{24\cdot 0,35}{12,401} \right\} = 0,95,$$

или

$$P\left\{ 0,213\ldots < \sigma^2 < 0,677\ldots \right\} = 0,95$$

— искомые интервальные оценки.

Приближённые (асимптотические) доверительные интервалы

Пусть $\{X_1, \dots, X_n\}$ – выборка, порождённая СВ X, имеющей неизвестное математическое ожидание θ и известную дисперсию σ^2. Требуется предложить интервальные оценки для θ.

Для случая, когда X имеет нормальное распределение, данная задача решена в лекции 8. Пусть теперь X имеет распределение, отличное от нормального. Рассмотрим СВ

$$T_n = \frac{\overline{X}_n - \theta}{\sigma/\sqrt{n}},$$

где $\overline{X}_n = \frac{X_1 + \dots + X_n}{n}$ – выборочное среднее. По центральной предельной теореме (см. соответствующую лекцию осеннего семестра) последовательность СВ $T_1, T_2, \dots, T_n \dots$ при $n \to \infty$ сходится к СВ, имеющей стандартное нормальное распределение. Это позволяет при больших n СВ T_n приближенно считать случайной величиной, имеющей стандартное нормальное распределение. Что, в свою очередь, позволяет получение в лекции 8 интервальные оценки

$$P\left\{\overline{X}_n - \frac{\Delta \cdot \sigma}{\sqrt{n}} < \theta < \overline{X}_n + \frac{\Delta \sigma}{\sqrt{n}}\right\} = \gamma, \text{ где } \gamma = 2\int_0^{\Delta} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\, dt,$$

считать приближенными интервальными оценками для θ при больших n.

Аналогично можно рассуждать и в случае, когда генеральная дисперсия σ^2 неизвестна, и полученные в лекции 9 интервальные оценки

$$P\left\{\overline{X}_n - \frac{\Delta \cdot \tilde{S}_n}{\sqrt{n}} < \theta < \overline{X}_n + \frac{\Delta \cdot \tilde{S}_n}{\sqrt{n}}\right\} = \gamma, \qquad (*)$$

где $\gamma = 2\int_0^{\Delta} s_{n-1}(t)\,dt$, $s_{n-1}(t)$ – плотность распределения Стьюдента с $(n-1)$ степенями свободы,

считать приближенными интервальными оценками для θ при больших n.

<u>Пример 2</u> Население города составляет 1 000 000 человек. Для случайно отобранных $n=625$ жителей средний возраст составил 33 года (реализация СВ $\overline{X}_n$), а среднеквадратичное отклонение – 15 лет (реализация СВ $\tilde{S}_n$). Найти приближенный 0,95-доверительный интервал для среднего возраста θ жителей города.

<u>Решение</u> По формуле (*) получим

$$P\left\{33 - \frac{\Delta \cdot 15}{25} < \theta < 33 + \frac{\Delta \cdot 15}{25}\right\} = 0{,}95.$$

Здесь $\int_0^{\Delta} s_{n-1}(t)\,dt = \frac{\gamma}{2} \Rightarrow \int_{-\infty}^{\Delta} s_{n-1}(t)\,dt = \frac{1}{2} + \frac{\gamma}{2} = 0{,}975$,

т.е. Δ есть квантиль уровня 0,975 распределения Стьюдента с $n-1$ степенями свободы. По таблицам находим $\Delta = 1{,}96$. В итоге

ответ: $P\{31{,}824 < \theta < 34{,}176\} = 0{,}95$

Приближенный доверительный интервал для неизвестного параметра распределения Бернулли

Напомним, что распределение Бернулли — это распределение дискретной СВ, определяемое таблицей:

X	0	1
P	$1-\theta$	θ

,

где $\theta \in (0,1)$ — параметр распределения Бернулли.

Пусть $\{X_1, \dots, X_n\}$ — выборка, порожденная СВ X, имеющей распределение Бернулли с неизвестным параметром θ. Найдём приближенные интервальные оценки для θ, опираясь на результат (*).

Обозначим через

$$\hat{\theta} = \frac{X_1 + \dots + X_n}{n} = \overline{X}_n$$

точечную оценку для θ. Поскольку объём выборки n предполагается большим, то

$$\vec{S}_n^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X}_n)^2 \approx \frac{1}{n} \sum_{i=1}^{n} (X_i - \hat{\theta})^2.$$

Покажем, что

$$\frac{1}{n} \sum_{i=1}^{n} (X_i - \hat{\theta})^2 = \hat{\theta}(1-\hat{\theta}).$$

Обозначив $X_1 + \dots + X_n = K$ (т.е. K — число выпавших единиц при n испытаниях),

найдём:

$$\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\hat{\theta}\right)^2=\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\frac{K}{n}\right)^2=\frac{1}{n^3}\sum_{i=1}^{n}\left(nX_i-K\right)^2=$$

$$=\frac{1}{n^3}\sum_{i=1}^{n}\left(n^2X_i^2-2nKX_i+K^2\right)=$$

$$=\frac{1}{n^3}\left\{n^2\sum_{i=1}^{n}X_i^2-2nK\sum_{i=1}^{n}X_i+nK^2\right\}=$$

{в силу специфики нашей СВ X
$$\sum_{i=1}^{n}X_i^2=\sum_{i=1}^{n}X_i=K$$
}

$$=\frac{1}{n^3}\left\{n^2\cdot K-2nK\cdot K+nK^2\right\}=\frac{1}{n^3}\left\{n^2K-nK^2\right\}=$$

$$=\frac{K}{n}-\frac{K^2}{n^2}=\frac{K}{n}\left(1-\frac{K}{n}\right)=\frac{X_1+\ldots+X_n}{n}\left(1-\frac{X_1+\ldots+X_n}{n}\right)=$$

$$=\hat{\theta}\left(1-\hat{\theta}\right),$$ что и т.д.

Таким образом, в соответствии с (*) искомые интервальные оценки имеют вид:

$$P\left\{\hat{\theta}-\Delta\cdot\sqrt{\frac{\hat{\theta}(1-\hat{\theta})}{n}}<\theta<\hat{\theta}+\Delta\cdot\sqrt{\frac{\hat{\theta}(1-\hat{\theta})}{n}}\right\}=\gamma, \quad (**)$$

где

$$\gamma=2\int_0^{\Delta}S_{n-1}(t)\,dt,$$ $S_{n-1}(t)$ — плотность распределения Стьюдента с $(n-1)$ степенями свободы

Пример 3. Пусть в условиях примера на стр. 6 из отобранных $n = 625$ жителей ~~год~~ города оказалось 125 учащихся (т.е. школьников или студентов). Найти приближённый 95%-й доверительный интервал для доли θ учащихся среди всех жителей города.

Решение. Имеем

$$\hat{\theta} = \frac{125}{625} = 0{,}2 ,$$

так что в соответствии с формулой (**) получим

$$P\left\{0{,}2 - \Delta\cdot\sqrt{\frac{0{,}2\cdot(1-0{,}2)}{625}} < \theta < 0{,}2 + \Delta\sqrt{\frac{0{,}2\cdot(1-0{,}2)}{625}}\right\} = 0{,}95,$$

где

$$0{,}95 = 2\cdot\int_0^{\Delta} s_{625-1}(t)\,dt \implies \Delta = 1{,}96.$$

Окончательно

$$P\{0{,}16864 < \theta < 0{,}23136\} = 0{,}95$$

— искомая интервальная оценка: с вероятностью 0,95 доля учащихся среди жителей города попадает в интервал от 0,16864 до 0,23136.

Информация об описке в формулировке задачи №4 из домашнего задания 2

В формулировке задачи №4 из домашнего задания 2 замечена следующая описка: фрагмент текста „где $\theta \in (0,1)$ — неизвестный параметр" должен быть заменён на „где ~~$\frac{1}{\theta} \in (0,1)$~~ $\theta \in (1,+\infty)$ — неизвестный параметр".