

Лекция 13

Проверка непараметрических гипотез

Пусть выборка $Z_n = (X_1, \dots, X_n)$ соответствует некоторому распределению с неизвестной ф.р. $F(x)$.

Определение Непараметрической гипотезой называется предположение $H_0: F(x) \text{ есть } F_0(x)$, где $F_0(x)$ — некоторая известная ф.р.

1. Будем сначала считать, что $F_0(x)$ задано дискретное распределение

$$\begin{array}{cccc} X & \xi_1 & \xi_2 & \dots & \xi_k \\ P & p_1 & p_2 & \dots & p_k \end{array}$$

По выборке Z_n построим относительные частоты

$$p_m^* = \frac{n_m}{n}, \quad m=1, 2, \dots, k,$$

где n_m — случайное число элементов выборки, равных ξ_m ; n — объем выборки.

Определение Статистикой хи-квадрат (статистикой Пирсона) называется функция выборки

$$G_n = G(Z_n) = \sum_{m=1}^k \frac{(n_m - np_m)^2}{np_m} = n \sum_{m=1}^k \frac{(p_m - p_m^*)^2}{p_m}.$$

Смысл G_n — некоторая мера расхождения между теоретическими вероятностями p_m и их оценками p_m^* , полученными по результатам наблюдений.

Теорема Если Z_n соответствует распределению $F_0(x)$, т.е. гипотеза H_0 верна, то G_n асимптотически распределена по закону хи-квадрат с $k=k-1$ степенями свободы.

$$G_n \xrightarrow[n \rightarrow \infty]{\text{нораспр.}} \chi_k^2.$$

Возможная схема доказательства

Рассмотрим k -мерный единичный вектор

$$\vec{u}_0 = (\sqrt{p_1}, \dots, \sqrt{p_k})^T.$$

Дополним его до ортонормированного базиса $\vec{u}_0, \vec{u}_1, \dots, \vec{u}_{k-1}$ в R^k . Пусть

~~то~~ $u_j^{(1)}, u_j^{(2)}, \dots, u_j^{(k)}$ — компоненты вектора $\vec{u}_j$,
 $j=0, 1, \dots, k-1$

(так что $u_0^{(1)} = \sqrt{p_1}, u_0^{(2)} = \sqrt{p_2}, \dots, u_0^{(k)} = \sqrt{p_k}$).

Если $\vec{e}_1 = (1, 0, \dots, 0)^T, \vec{e}_2 = (0, 1, \dots, 0)^T, \dots, \vec{e}_k = (0, 0, \dots, 1)^T$ — стандартный ортонормированный базис в R^k , то

$$(\vec{u}_0, \vec{u}_1, \dots, \vec{u}_{k-1}) = (\vec{e}_1, \vec{e}_2, \dots, \vec{e}_k) U,$$

где матрица

$$U = \begin{pmatrix} u_0^{(1)} & u_1^{(1)} & \dots & u_{k-1}^{(1)} \\ u_0^{(2)} & u_1^{(2)} & \dots & u_{k-1}^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ u_0^{(k)} & u_1^{(k)} & \dots & u_{k-1}^{(k)} \end{pmatrix}$$

— матрица перехода от ортонормированного базиса $u = (\vec{u}_0, \dots, \vec{u}_{k-1})$ $E = (\vec{e}_1, \dots, \vec{e}_k)$ к ортонормированному базису $u = (\vec{u}_0, \dots, \vec{u}_{k-1})$

или

$$G_n = \sum_{m=1}^{K-1} W_m^2, \quad (**)$$

Случайная величина K_m имеет биномиальное распределение с параметрами n и p_m , так что математическое ожидание СВ Y_m равно нулю при $\forall m=1, \dots, K$:

$$MY_m = 0, \quad m=1, 2, \dots, K,$$

откуда в силу (x) $MY_m = 0, \quad m=1, 2, \dots, K-1$.

Далее

$$Y_m = \frac{K_m - n p_m}{\sqrt{n p_m}} = \sqrt{1-p_m} \cdot \frac{K_m - n p_m}{\sqrt{n p_m (1-p_m)}},$$

так что при $n \rightarrow \infty$ распределение СВ Y_m будет стремиться (по ЦПТ) к нормальному распределению СВ с нулевым математическим ожиданием и дисперсией $(\sqrt{1-p_m})^2$. Значит (см. (x)) все случайные величины $W_1, W_2, \dots, W_{K-1}$ в пределе при $n \rightarrow \infty$ могут быть нормально распределены с нулевым математическим ожиданием.

С учетом соотношений (*) можно показать, что СВ $W_1, \dots, W_{K-1}$ при $n \rightarrow \infty$ будут иметь единичные дисперсии и нулевые коэф. корреляции, а это значит, что


СВ G_n при $n \rightarrow \infty$ стремиться к распределению χ^2 с $(K-1)$ степенями свободы. Теорема доказана.

Теорема позволяет предложить следующий критерий проверки гипотезы $H_0: F(x) = F_0(x)$ на уровне значимости $\alpha \in (0; 1)$.


1) По реализации Z_n выборки Z_n вычисляем соответствующую статистику G_n .

2) Находим квантили $u_{1-\alpha}$ распределения χ^2_{k-1} и определяем критическую область $\Delta_\alpha = (u_{1-\alpha}, +\infty)$ и доверительную область $\bar{\Delta}_\alpha = [0; u_{1-\alpha}]$.

3) Если $G_n \in \Delta_\alpha$, то H_0 отвергается на уровне значимости α ; если же $G_n \in \bar{\Delta}_\alpha$, то H_0 принимается.



2. Пусть теперь $F_0(x)$ задаёт непрерывное распределение. В этом случае область всех возможных значений СВ X разбивается на K непрерывающихся промежутков: $\delta_1, \dots, \delta_m, \dots, \delta_K$



В этом случае

n_m — число элементов выборки, попавших в промежуток δ_m , $m=1, 2, \dots, K$;

$p_m = P\{X \in \delta_m\}$ — теоретическая вероятность попадания в δ_m .

После чего проверка проводится по той же схеме, что и для дискретной СВ.

3. Если $F_0(x)$ зависит от l неизвестных параметров $\theta_1, \dots, \theta_l$, то в критерии Пирсона нужно предварительно заменить $\theta_1, \dots, \theta_l$ на их оценки $\hat{\theta}_1, \dots, \hat{\theta}_l$, полученные по методу максимального правдоподобия. В этом случае статистика G_n (см. стр. 1) будет иметь распределение χ^2 с числом степеней свободы $r = K - 1 - l$.

На практике критерий Пирсона даёт приемлемые результаты, если

- 1) объём выборки $n \geq 50$;
- 2) соблюдено условие $n \cdot p_m \geq 5$, $m=1, 2, \dots, K$.

При этом при выборе числа K интервалов при непрерывном распределении $F_0(x)$ используют формулу $K = 1 + [3,32 \sqrt{\lg n}]$ (формула Стерджесса), где $[a]$ — целая часть числа a .

Пример Монета подброшена $n = 4000$ раз, в результате чего герб выпал 2028 раз. Проверим на уровне значимости $\alpha = 0,05$ гипотезу H_0 о том, что монета симметрична.

Решение. Теперь идёт о проверке распределение дискретной СВ X :

X	1	0
P	$1/2$	$1/2$

где событие $\{X=1\}$ означает выпадение герба, а $\{X=0\}$ — выпадение решки. Тогда для реализации событий g_n статистики G_n из критерия Пирсона:

$$\begin{aligned}
 g_n &= \sum_{m=1}^k \frac{(n_m - n \cdot p_m)^2}{n p_m} = \sum_{m=1}^2 \frac{(n_m - n \cdot p_m)^2}{n p_m} = \\
 &= \frac{(n_1 - n p_1)^2}{n p_1} + \frac{(n_2 - n p_2)^2}{n p_2} = \\
 &= \frac{(2028 - 4000 \cdot \frac{1}{2})^2}{4000 \cdot \frac{1}{2}} + \frac{(1972 - 4000 \cdot \frac{1}{2})^2}{4000 \cdot \frac{1}{2}} = \\
 &= \frac{28^2}{2000} + \frac{28^2}{2000} = 0,784.
 \end{aligned}$$

Критическая область имеет вид $(u_{1-\alpha}; +\infty)$, где $u_{1-\alpha}$ есть квантили уровня $1-\alpha$ распределения χ^2 с $r = k-1 = 2-1 = 1$ степенями свободы. По условию $\alpha = 0,05 \Rightarrow u_{1-\alpha} = u_{0,95} = 3,84$. Поскольку $0,784 \notin (3,84; +\infty)$, то гипотезу H_0 принимаем на уровне значимости 0,05.