

Лекция 14

Проверка гипотезы однородности (продолжение)

Продолжим рассмотрение примеров на применение критерия хи-квадрат, начавшее в лекции 13.

Пример 1. Пусть реализации выборки объема $n=50$ (соответствующей некоторому распределению $F(x)$) имеют вид

65	48	11	76	74	17	46	85	9	50
37	77	69	74	45	80	12	43	56	35
72	70	80	15	45	31	82	23	74	45
35	9	98	17	77	39	27	72	14	43
55	2	10	9	69	91	58	17	73	23

На уровне значимости $\alpha=0,05$ проверить гипотезу $H_0: F(x)$ соответствует равномерному распределению на $[0;100]$.

Решение. Если H_0 верна, то множество возможных значений СВ X есть отрезок $[0;100]$. Разобьем его на $k=5$ промежутков.

$$S_1=[0,20) \quad S_2=[20,40) \quad S_3=[40,60) \quad S_4=[60,80) \quad S_5=[80,100]$$

и найдем соответствующие значения n_m , $m=1,2,3,4,5$ (n_m — число чисел из таблицы, попавших в промежуток S_m):

$$n_1=12 \quad n_2=8 \quad n_3=11 \quad n_4=13 \quad n_5=6$$

Далее, поскольку

$$p_m = P\{X \in S_m\} = \frac{20}{100} = 0,2 \text{ для всех } m=1,2,3,4,5,$$

то реализации g_n статистики G_n будут равны

$$g_n = \sum_{m=1}^k \frac{(n_m - np_m)^2}{np_m} \equiv \left(\sum_{m=1}^k \frac{(n_m)^2}{np_m} \right) - n =$$

$$= \left(\frac{12^2 + 8^2 + 11^2 + 13^2 + 6^2}{50 \cdot 0,2} \right) - 50 = 3,4$$

Теперь назовем критическую область

$$\Delta_{\alpha} = (u_{1-\alpha}, +\infty),$$

где $u_{1-\alpha}$ есть квантиль уровня $1-\alpha$ распределения χ^2_r с числом степеней свободы $r = k-1 = 5-1 = 4$:

$$u_{1-\alpha} = u_{0,95} \Big|_{r=4} = 9,49$$

Таким образом, значение $g_n = 3,4$ не попадает в критическую область $(9,49; +\infty)$ и, следовательно, гипотеза H_0 принимается на уровне значимости $\alpha = 0,05$.

Пример 2 Проверим теперь в условиях предыдущего примера гипотезу H_0 : изучаемая СВ X имеет нормальное распределение.

Решение. Если H_0 верна, то $X \sim N(m_x, D_x)$. Здесь $F_0(x)$ (предполагаемое по H_0 функцией распределения СВ X) содержит ~~два~~ неизвестных параметра: m_x и D_x . Возьмем соответствующие функции оценок максимального правдоподобия для m_x и D_x (см. лекцию 6):

$$\hat{m}_x = \bar{x}_n = \frac{1}{n} \sum_{k=1}^n x_k = 47,9;$$

$$\hat{D}_x = \frac{1}{n} \sum_{k=1}^n (x_k - \hat{m}_x)^2 = 698,02$$

$$\Rightarrow \hat{\sigma}_x = \sqrt{\hat{D}_x} = 26,42.$$

Теперь множественном возможных значений СВ X является $(-\infty; +\infty)$. Пусть пороговому $k=5$ и при этом

$$S_1 = (-\infty, 20) \quad S_2 = [20, 40) \quad S_3 = [40, 60) \quad S_4 = [60, 80) \quad S_5 = [80, +\infty)$$

Далее вероятности $p_m = P\{X \in S_m\}$ берем так, как если бы СВ X имела нормальное распределение с параметрами $MX = \hat{m}_x$ и $DX = \hat{D}_x$, где $\hat{m}_x$ и $\hat{D}_x$ оценены выше. В результате получим

$$np_1 = 20,25 \quad np_2 = 14,5 \quad np_3 = 10,15 \quad np_4 = 4,04 \quad np_5 = 1,06$$

Значения n_1, n_2, n_3, n_4, n_5 те же самые, что и в предыдущем примере. Для функции g_n статистики G_n получим

$$g_n = \left(\sum_{m=1}^k \frac{(n p_m)^2}{n p_m} \right) - k =$$

$$= \left(\frac{144}{20,25} + \frac{64}{14,5} + \frac{121}{10,15} + \frac{169}{4,04} + \frac{36}{1,06} \right) - 50 = 49,24$$

Критическая область есть

$$\Delta_{\alpha} = (u_{1-\alpha}; +\infty),$$

где $u_{1-\alpha}$ есть квантили уровня $1-\alpha$ распределения χ^2_r с $r = k-1-l = 5-1-2 = 2$ степенями свободы; получаем

$$u_{1-\alpha} = u_{0,95} \Big|_{r=2} = 5,99$$

Поскольку $g_n = 49,24$ попадает в критическую область $\Delta_{\alpha} = (5,99; +\infty)$, то гипотеза H_0 отвергается на уровне значимости $\alpha = 0,05$.

Использование критерия
хи-квадрат
для проверки гипотезы
о независимости случайных величин

Пусть X и Y - дискретные СВ, опреде-
ленные законами распределения

$$\begin{array}{ll} X & a_1 \ a_2 \dots a_i \dots a_s \\ P & p_1 \ p_2 \dots p_i \dots p_s \end{array} \quad \begin{array}{ll} Y & b_1 \ b_2 \dots b_j \dots b_t \\ P & q_1 \ q_2 \dots q_j \dots q_t \end{array}$$

Пусть Z_n - двумерная выборка, поро-
жденная вектором (X, Y) . Пусть

n_{ij} - число опытов, в которых реализа-
ция выборки Z_n есть (a_i, b_j) , где
 $i = 1, 2, \dots, s; j = 1, 2, \dots, t$.

Обозначим $N_i = \sum_{j=1}^t n_{ij}$, $M_j = \sum_{i=1}^s n_{ij}$. Вве-
дем статистику $\tilde{G}_n$, аналогичную ста-
тистике G_n (см. стр. 1 лекции 13):

$$\tilde{G}_n = \sum_{i=1}^s \sum_{j=1}^t \frac{(n_{ij} - n p_i^* q_j^*)^2}{n p_i^* q_j^*}, \quad (*)$$

где $p_i^* = \frac{N_i}{n}$ и $q_j^* = \frac{M_j}{n}$ - частота появле-
ния a_i и b_j . Имеем место результатов,
аналогичный теореме на стр. 2 лекции 13:

Теорема Если верна гипотеза о неза-
висимости дискретных СВ X и Y , то

$$\tilde{G}_n \xrightarrow[n \rightarrow \infty]{\text{по распр.}} \chi_r^2, \text{ где } r = (s-1)(t-1).$$

Поэтому гипотезу о независимости
отвергаем, если реализации $\tilde{G}_n$ статисти-
ки $\tilde{G}_n$ попадают в критическую об-

часть $\Delta_\alpha = (u_{1-\alpha}, +\infty)$, где α - уровень значимости критерия, а $u_{1-\alpha}$ есть квантили уровня $1-\alpha$ распределения χ^2_α с $\alpha = (S-1)(t-1)$ степенями свободы.

Пример 3. Связем со вступительной кампанией в некоторый вуз две случайные величины:

$$X = \begin{cases} 1, & \text{если очередной абитуриент} \\ & \text{поступил,} \\ 0, & \text{если - " - не поступил;} \end{cases}$$

$$Y = \begin{cases} 1, & \text{если очередной абитуриент,} \\ & \text{мужчина,} \\ 0, & \text{если - " - женщина.} \end{cases}$$

По окончании вступительных экзаменов выяснилось следующее:

	$Y=1$	$Y=0$
$X=1$	97	40
$X=0$	263	42

То есть всего поступило $97+263+40+42=442$ абитуриента, из которых мужчин было $97+263=360$, а женщин $40+42=82$, причем поступивших мужчин было 97, а поступивших женщин - 40.

Требуется на уровне значимости $\alpha=0,05$ проверить гипотезу о независимости СВ X и Y , т.е. проверить гипотезу о том, связанны ли факт поступления и половая принадлежность абитуриента.

Решение. Возводимая критерием χ^2 . Правую часть равенства (*)

можно переписать к виду

$$\tilde{G}_n = n \left(\sum_{i=1}^s \sum_{j=1}^t \frac{(n_{ij})^2}{N_i M_j} - 1 \right),$$

что при $s=t=2$ даёт

$$\tilde{G}_n = \frac{n(n_{11}n_{22} - n_{12}n_{21})^2}{N_1 N_2 M_1 M_2}.$$

В нашем случае

$$n_{11}=97, n_{12}=40, n_{21}=263, n_{22}=42,$$

$$N_1 = n_{11} + n_{12} = 137, N_2 = n_{21} + n_{22} = 305,$$

$$M_1 = n_{11} + n_{21} = 360, M_2 = n_{12} + n_{22} = 82,$$

$$n = n_{11} + n_{12} + n_{21} + n_{22} = 442,$$

так что реализация $\tilde{g}_n$ статистики $\tilde{G}_n$ равна

$$\tilde{g}_n = \frac{442(97 \cdot 42 - 40 \cdot 263)^2}{137 \cdot 305 \cdot 360 \cdot 82} = 14,89.$$

При $\alpha=0,05$ критическая область $\Delta_\alpha = (u_{1-\alpha}, +\infty)$, где $u_{1-\alpha}$ — квантили уровня $1-\alpha=0,95$ распределение χ^2_r с $r = (s-1)(t-1) = (2-1)(2-1) = 1$ степенью свободы, т.е. $u_{1-\alpha} = 3,84$. Поскольку реализация $\tilde{g}_n = 14,89$ попадает в критическую область $(3,84, +\infty)$, то гипотеза о независимости СВ X и Y следует отвергнуть на уровне значимости $\alpha=0,05$.