

Лекция 10

Интервальные оценки неизвестной дисперсии нормального распределения при неизвестном математическом ожидании. Приближенные (асимптотические) доверительные интервалы

Пусть выборка $\{X_1, \dots, X_n\}$ порождена случайной величиной X , имеющей нормальное распределение с неизвестным математическим ожиданием a и неизвестной дисперсией $\theta = \sigma^2$. Найдём интервальные оценки для неизвестного параметра θ .

С этой целью рассмотрим статистику

$$Z = \frac{(n-1)\tilde{S}_n^2}{\sigma^2},$$

где

$$\tilde{S}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

— исправленная выборочная дисперсия,

$$\bar{X}_n = \frac{X_1 + \dots + X_n}{n}$$

— выборочное среднее.

Теорема (без доказательства). Если случайные величины $X_1, \dots, X_n$ независимы и распределены по нормальному закону с одинаковыми математическими ожиданиями и дисперсиями σ^2 , то случайная величина Z имеет распределение χ^2 с $(n-1)$ степенями свободы, т.е. плотность распределения Z даётся формулой

$$f_{\chi^2(n-1)}(x) = \frac{1}{2^{(n-1)/2} \Gamma((n-1)/2)} x^{(n-1)/2-1} e^{-x/2}, \quad x > 0,$$

где $\Gamma(\cdot)$ — гамма-функция. (На стр. 5 лекции 9 выписана плотность распределения χ^2 с n степенями свободы.)

Введенная статистика Z удовлетворяет требованиям п. а) и б) из стр. 2 лекции 8 (такие статистики называются *центральными*) и может быть использована для нахождения интервальных оценок для θ по той же схеме, что была описана в лекции 8.

Пусть статистики θ_L и θ_R таковы, что

$$P\{\theta_L < \theta < \theta_R\} = \gamma,$$

где γ — заданная доверительная вероятность. Выберем числа $\alpha > 0$ и $\beta > \alpha$ так, чтобы

$$P\left\{\alpha < \frac{(n-1)\tilde{S}_n^2}{\theta} < \beta\right\} = \gamma,$$

или

$$P\left\{\frac{(n-1)\tilde{S}_n^2}{\beta} < \theta < \frac{(n-1)\tilde{S}_n^2}{\alpha}\right\} = \gamma.$$

Потребуем, чтобы интервальные оценки были симметричны по вероятности (см. лекцию 8), т.е.

$$P\left\{\theta < \frac{(n-1)\tilde{S}_n^2}{\beta}\right\} = P\left\{\theta > \frac{(n-1)\tilde{S}_n^2}{\alpha}\right\} = \frac{1-\gamma}{2}.$$

Эти условия позволяют однозначно определить α и β :

$$P\left\{\theta < \frac{(n-1)\tilde{S}_n^2}{\beta}\right\} = \frac{1-\gamma}{2} \iff P\left\{\frac{(n-1)\tilde{S}_n^2}{\theta} > \beta\right\} = \frac{1-\gamma}{2}.$$

$$\iff \int_{\beta}^{\infty} f_{\chi^2(n-1)}(x) dx = \frac{1-\gamma}{2}$$

по таблицам распределения $\chi^2(n-1)$ определяем значение β ,

$$P\left\{\theta > \frac{(n-1)\tilde{S}_n^2}{\alpha}\right\} = P\left\{\frac{(n-1)\tilde{S}_n^2}{\theta} < \alpha\right\} = \frac{1-\gamma}{2}.$$

$$\iff \int_0^{\alpha} f_{\chi^2(n-1)}(x) dx = \frac{1-\gamma}{2}$$

по таблицам распределения $\chi^2(n-1)$ определяем значение α .

Терминологическое дополнение. Пусть $F(x)$ — функция распределения случайной величины X . Корень уравнения $F(x) = q$ называется *квантилью уровня q* (или q -квантилью) случайной величины X или соответствующего распределения. Таким образом,

$$\alpha = \left\{ \begin{array}{l} \text{квантиль уровня } (1-\gamma)/2 \text{ распределения } \chi^2 \\ \text{с } (n-1) \text{ степенями свободы} \end{array} \right\},$$

$$\beta = \left\{ \begin{array}{l} \text{квантиль уровня } 1 - (1-\gamma)/2 = (1+\gamma)/2 \text{ распределения } \chi^2 \\ \text{с } (n-1) \text{ степенями свободы} \end{array} \right\}.$$

Пример 1. Изучается нормально распределенная случайная величина с неизвестным математическим ожиданием и дисперсией. По результатам 25 испытаний найдена исправленная выборочная дисперсия $\hat{S}_{25}^2 = 0,35$. Найти симметричные по вероятности интервальные оценки, покрывающие неизвестную генеральную дисперсию σ^2 с доверительной вероятностью $\gamma = 0,95$.

Решение. В соответствии с общими результатами имеем

$$P\left\{\frac{(25-1) \cdot 0,35}{\beta} < \sigma^2 < \frac{(25-1) \cdot 0,35}{\alpha}\right\} = 0,95,$$

где

$$\alpha = \{\text{квантиль уровня } (1 - 0,95)/2 = 0,025\} = 12,401$$

(по таблицам распределения χ^2 с 24 степенями свободы),

$$\beta = \{\text{квантиль уровня } (1 + 0,95)/2 = 0,975\} = 39,364$$

(по таблицам распределения χ^2 с 24 степенями свободы).

Следовательно,

$$P\left\{\frac{24 \cdot 0,35}{39,364} < \sigma^2 < \frac{24 \cdot 0,35}{12,401}\right\} = 0,95,$$

или

$$P\{0,213 \dots < \sigma^2 < 0,677 \dots\} = 0,95.$$

Это искомые интервальные оценки.

1 Приближенные (асимптотические) доверительные интервалы

Пусть $\{X_1, \dots, X_n\}$ — выборка, порождённая случайной величиной X , имеющей неизвестное математическое ожидание θ и известную дисперсию σ^2 . Требуется предложить интервальные оценки для θ .

Для случая, когда X имеет нормальное распределение, данная задача решена в лекции 8. Пусть теперь X имеет распределение, отличное от нормального. Рассмотрим случайную величину

$$T_n = \frac{\bar{X}_n - \theta}{\sigma/\sqrt{n}},$$

где $\bar{X}_n = \frac{X_1 + \dots + X_n}{n}$ — выборочное среднее (точечная оценка θ). По центральной предельной теореме последовательность $T_1, T_2, \dots$ при $n \rightarrow \infty$

сходится к случайной величине, имеющей стандартное нормальное распределение. Это позволяет при больших n считать T_n приближённо стандартной нормальной случайной величиной. Что, в свою очередь, позволяет полученные в лекции 8 интервальные оценки

$$P\left\{\bar{X}_n - \Delta \frac{\sigma}{\sqrt{n}} < \theta < \bar{X}_n + \Delta \frac{\sigma}{\sqrt{n}}\right\} = \gamma, \quad \gamma = 2 \int_0^{\Delta} \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$

считать приближёнными интервальными оценками для θ при больших n .

Аналогично можно рассуждать и в случае, когда генеральная дисперсия σ^2 неизвестна, и полученные в лекции 9 интервальные оценки

$$P\left\{\bar{X} - \Delta \frac{\tilde{S}_n}{\sqrt{n}} < \theta < \bar{X} + \Delta \frac{\tilde{S}_n}{\sqrt{n}}\right\} = \gamma \quad (*)$$

где $\gamma = 2 \int_0^{\Delta} s_{n-1}(t) dt$, $s_{n-1}(t)$ — плотность распределения Стьюдента с $n-1$ степенями свободы, считать приближёнными интервальными оценками для θ при больших n .

Пример 2. Население города составляет 1 000 000 человек. Для случайно отобранных $n = 625$ жителей средний возраст составил 33 года (реализация $\bar{X}$), а среднеквадратичное отклонение — 15 лет (реализация $\tilde{S}_n$). Найти приближённый 0,95-доверительный интервал для среднего возраста жителей города.

Решение. По формуле (*) получим

$$P\left\{33 - \Delta \frac{15}{25} < \theta < 33 + \Delta \frac{15}{25}\right\} = 0,95.$$

Здесь

$$\int_0^{\Delta} s_{n-1}(t) dt = \frac{\gamma}{2} \implies \int_{-\infty}^{\Delta} s_{n-1}(t) dt = \frac{1}{2} + \frac{\gamma}{2} = 0,975,$$

т.е. Δ есть квантиль уровня 0,975 распределения Стьюдента с $n-1$ степенями свободы. По таблицам находим $\Delta = 1,96$. В итоге

$$P\{31,824 < \theta < 34,176\} = 0,95.$$

2 Приближенный доверительный интервал для неизвестного параметра распределения Бернулли

Напомним, что распределение Бернулли — это распределение дискретной случайной величины, определяемое таблицей:

x	0	1
P	$1 - \theta$	θ

где $\theta \in (0, 1)$ — параметр распределения Бернулли.

Пусть $\{X_1, \dots, X_n\}$ — выборка, порожденная случайной величиной X , имеющей распределение Бернулли с неизвестным параметром θ . Найдём приближённые интервальные оценки для θ , опираясь на результаты (*). Обозначим через

$$\hat{\theta} = \frac{X_1 + \dots + X_n}{n} = \bar{X}$$

точечную оценку θ . Поскольку объём выборки n предполагается большим, то

$$\tilde{S}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\theta})^2.$$

Покажем, что

$$\frac{1}{n} \sum_{i=1}^n (X_i - \hat{\theta})^2 = \hat{\theta}(1 - \hat{\theta}).$$

Обозначив $X_1 + \dots + X_n = K$ (т.е. K — число выпавших единиц при n испытаниях), найдём:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\theta})^2 &= \frac{1}{n} \sum_{i=1}^n \left(X_i - \frac{K}{n} \right)^2 = \frac{1}{n^3} \sum_{i=1}^n (nX_i - K)^2 = \\ &= \frac{1}{n^3} \sum_{i=1}^n (n^2 X_i^2 - 2nKX_i + K^2) = \frac{1}{n^3} \left\{ n^2 \sum_{i=1}^n X_i^2 - 2nK \sum_{i=1}^n X_i + nK^2 \right\} \end{aligned}$$

В силу специфики нашей случайной величины X :

$$\sum_{i=1}^n X_i^2 = \sum_{i=1}^n X_i = K,$$

Подставляя, получаем

$$\begin{aligned} \frac{1}{n^3} \{n^2 K - 2nK \cdot K + nK^2\} &= \frac{1}{n^3} \{n^2 K - nK^2\} = \\ &= \frac{K}{n} \left(1 - \frac{K}{n}\right) = \frac{X_1 + \dots + X_n}{n} \left(1 - \frac{X_1 + \dots + X_n}{n}\right) = \hat{\theta}(1 - \hat{\theta}), \end{aligned}$$

что и требовалось показать.

Таким образом, в соответствии с (*) искомые интервальные оценки имеют вид

$$P\left\{\hat{\theta} - \Delta \sqrt{\frac{\hat{\theta}(1 - \hat{\theta})}{n}} < \theta < \hat{\theta} + \Delta \sqrt{\frac{\hat{\theta}(1 - \hat{\theta})}{n}}\right\} = \gamma, \quad (**)$$

где

$$\Delta = 2 \int_0^\Delta s_{n-1}(t) dt,$$

а $s_{n-1}(t)$ — плотность распределения Стьюдента с $(n - 1)$ степенями свободы.

Пример 3. Пусть в условиях примера на стр. 6 из отобранных $n = 625$ жителей города оказалось 125 учащихся (т.е. школьников или студентов). Найти приближённый 95%-й доверительный интервал для доли учащихся среди всех жителей города.

Решение. Имеем

$$\hat{\theta} = \frac{125}{625} = 0,2,$$

так что в соответствии с формулой (**) получим

$$P\left\{0,2 - \Delta \sqrt{\frac{0,2 \cdot 0,8}{625}} < \theta < 0,2 + \Delta \sqrt{\frac{0,2 \cdot 0,8}{625}}\right\} = 0,95,$$

где

$$\Delta_{0,95} = 2 \int_0^{\Delta/2} f(t) dt \implies \Delta = 1,96.$$

Окончательно

$$P\{0,16864 < \theta < 0,23136\} = 0,95.$$

С вероятностью 0,95 доля учащихся среди жителей города попадает в интервал от 0,16864 до 0,23136.

Информация об опiske в формулировке задачи N4 из домашнего задания 2

В формулировке задачи N4 из домашнего задания 2 замечена следующая описка: фрагмент «где $\theta \in (0, 1)$ — неизвестный параметр» должен быть заменён на «где $\theta \notin (1, +\infty)$ — неизвестный параметр».