

## Лекция 1

Задачи и понятие матем. статистики.  
Генеральная и выборочная совокупности.  
Характеристики выборки. Гистограмма.

Математическая статистика изучает методы сбора и обработки статистических данных с целью получения теоретических и практических выводов вероятностного характера.

Пусть  $X$  - СВ, связанная с экспериментом  $E$ , с неизвестным законом распределения. Генеральная совокупность значений СВ  $X$  — множество всех возможных значений, которые может принимать СВ  $X$ . Выборочная совокупность значений СВ  $X$  объема  $n$  (или просто выборка объема  $n$ ) — совокупность  $n$  реализаций СВ  $X$

$$x_1, x_2, \dots, x_n, \quad (1)$$

полученных в результате проведения серии из  $n$  экспериментов  $E$ .

Задача математической статистики — построение надежных заключений о генеральной совокупности на основе анализа выборочной совокупности.

В общем случае выборочные значения (1) можно повторять:

$x_i$	$x_1$	$x_2$	$\dots$	$x_k$
$n_i$	$n_1$	$n_2$	$\dots$	$n_k$

(2)

где  $n_1 + n_2 + \dots + n_k = n$ ,  $x_1 < x_2 < \dots < x_k$ . Пара  $x_1, x_2, \dots, x_k$  называется вариационным рядом,



числа  $n_i, i=1, 2, \dots, k$ , — частотами, а  
числа  $w_i = \frac{n_i}{n}$  — относительными частотами,  
таблица (2) — распределением выборки.  
Астро, что

$$\sum_{i=1}^k w_i = 1.$$

Функции распределения СВ  $X$

$$F(x) = P\{X < x\}, \quad x \in (-\infty; \infty),$$

можем быть оценена (исходя из статистического восприятия вероятности) так:

$$P\{X < x\} \approx \frac{\sum_{i: x_i < x} n_i}{n},$$

где  $\sum_{i: x_i < x} n_i$  — сумма всех  $n_i$  таких, что  $x_i < x$ .

Обозначим  $n_x = \sum_{i: x_i < x} n_i$ . По определению, функции


$$F^*(x) = \frac{n_x}{n}$$

называется эмпирической функцией распределения СВ  $X$ , построенной по выборке (2). Очевидны свойства  $F^*(x)$ :


- 1)  $0 \leq F^*(x) \leq 1$ ;
- 2)  $F^*(x)$  — неубывающая функция;
- 3) поскольку в (2)  $x_1$  — наименьшее, а  $x_k$  — наибольшее значение выборки, то  $F^*(x) = 0$  при  $x \leq x_1$  и  $F^*(x) = 1$  при  $x > x_k$ .



Полный частот — ломанная, отрезки которой соединяют точки  $(x_1, n_1), \dots, (x_k, n_k)$



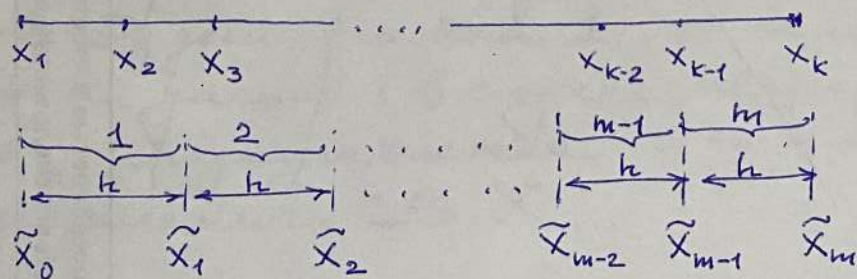
Полный относительный частот — ломанная, отрезки которой соединяют точки  $(x_1, w_1), \dots, (x_k, w_k)$ .



$$w_1 + w_2 + \dots + w_k = 1$$

### Гистограмма

Разобьем все значения  $x_1, x_2, \dots, x_k$  наблюдаемой СВ на какое-либо число  $m$  равных интервалов длины  $h$




Обозначим

$$\tilde{n}_j = \begin{cases} \text{сумма всех } n_i, \\ \text{где } x_{j-1} \leq x_i < x_j, j < m \\ x_{m-1} \leq x_i \leq x_m \end{cases}$$



Гистограммой часто называют ступенчатую фигуру, состоящую из прямоугольников, основаниями которой служат интервалы длиной  $h$ , а высоты равны  $\tilde{f}_j/h$ :



Площадь всех прямоугольников будет равна

$$\sum_{j=1}^m \frac{\tilde{f}_j}{h} \cdot h = n_1 + n_2 + \dots + n_k = n$$

- общему числу всех значений СВ. Если высоты прямоугольников сделаны равными  $\tilde{f}_j/nh$ , то соответствующая ступенчатая фигура называется нормированной гистограммой. В этом случае площадь всех прямоугольников будет равна 1, а сама гистограмма даст (в случае непрерывной СВ  $X$ ) представление о плотности распределения СВ  $X$ .

# Некоторые характеристики выборки

Рассмотрим выборочное распределение

$x_i$	$x_1$	$x_2$	$\dots$	$x_k$
$n_i$	$n_1$	$n_2$	$\dots$	$n_k$

$$n_1 + n_2 + \dots + n_k = n$$

Определим следующие характеристики выборки:

выборочное среднее

$$\bar{x} = \frac{x_1 n_1 + \dots + x_k n_k}{n}$$

выборочная дисперсия

$$D_x = \frac{(x_1 - \bar{x})^2 n_1 + \dots + (x_k - \bar{x})^2 n_k}{n}$$

Эмпирический начальный момент  
порядка  $s$

$$y_s = \frac{x_1^s n_1 + \dots + x_k^s n_k}{n}$$

Эмпирический центрированный момент  
порядка  $s$

$$\mu_s = \frac{(x_1 - \bar{x})^s n_1 + \dots + (x_k - \bar{x})^s n_k}{n}$$

Как видно, выборочное среднее — это эмпирический начальный момент 1-го порядка, а выборочная дисперсия — это эмпирический центрированный момент 2-го порядка.



Если есть выборочное распределение для системы двух случайных величин  $X$  и  $Y$ , т.е. таблица

	$Y=y_1$	$Y=y_2$	$\dots$	$Y=y_k$
$X=x_1$	$n_{11}$	$n_{12}$	$\dots$	$n_{1k}$
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
$X=x_r$	$n_{r1}$	$n_{r2}$	$\dots$	$n_{rk}$

где  $n_{ij}$  - частота пары  $(x_i, y_j)$ ,

то для СВ  $Z = f(X, Y)$ , где  $f(\dots)$  - заданная функция, выборочное среднее  $\bar{Z}$  определено по формуле

$$\bar{Z} = \frac{\sum_{i=1}^r \sum_{j=1}^k f(x_i, y_j) n_{ij}}{n},$$

где  $n = \sum_{i=1}^r \sum_{j=1}^k n_{ij}$ .

В частности, эмпирическая ковариация

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^k (x_i - \bar{x})(y_j - \bar{y}) n_{ij},$$

а эмпирический коэффициент корреляции

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{D_X D_Y}}.$$