Семинар 1

Задачи математической статистики. Генеральная и выборочная совокупности. Описательные статистики

1. **Основные задачи математической статистики:**

   - **Описание данных (Descriptive):** Сжатое представление выборки с помощью таблиц, графиков и числовых характеристик.
   - **Оценка параметров (Estimation):** По выборке оценить неизвестные параметры генерального распределения.
   - **Проверка гипотез (Testing):** Сделать статистический вывод о справедливости некоторого предположения о генеральной совокупности.
   - **Прогнозирование (Prediction):** Предсказание будущих наблюдений на основе имеющихся данных.

2. **Генеральная совокупность и выборка:**

   - **Генеральная совокупность** — полное множество всех объектов, обладающих изучаемым признаком. Её распределение (P или $F(x)$) часто неизвестно.
   - **Выборка объема** n ($X_n = (x_1, ..., x_n)$) — набор независимых наблюдений, извлеченных из генеральной совокупности. Символическая запись: $X_n \in P$.

3. **Числовые характеристики выборки (Выборочные моменты):**

   - **Меры центра:**

$$\text{Выборочное среднее: } \overline{x} = a_1^* = \frac{1}{n}\sum_{i=1}^{n} x_i$$

$$\text{Выборочная медиана: } \zeta^* = \begin{cases} x_{(m)}, & n = 2m-1 \\ \frac{x_{(m)}+x_{(m+1)}}{2}, & n = 2m \end{cases}$$

   - **Меры разброса:**

$$\text{Выборочная дисперсия (смещенная): } S^2 = a_2^{o*} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2$$

$$\text{Исправленная дисперсия (несмещенная): } s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2$$

$$\text{Стандартное отклонение: } s = \sqrt{s^2}$$

4. **Гистограмма:**

   - Графическое представление **эмпирического распределения** P_n.
   - При увеличении объема выборки и уменьшении ширины бинов гистограмма приближается к **функции плотности вероятности (PDF)** теоретического распределения.

Правило Стёрджеса для выбора числа бинов в гистограмме — эмпирическое правило для определения оптимального числа бинов (интервалов) при построении гистограммы. Оно основано на объёме выборки n:

$$k = 1 + \log_2 n$$

где:

- k — рекомендуемое число бинов (интервалов)
- n — объём выборки
- $\log_2$ — логарифм по основанию 2

На практике полученное значение округляют до ближайшего целого числа:

$$k_{\text{округ}} = 1 + \lfloor \log_2 n + 0.5 \rfloor$$

Пример 1. *Для выборки объёмом $n = 100$:*

$$k = 1 + \log_2 100 \approx 1 + 6.64 = 7.64 \approx 8$$

Рекомендуется использовать 8 бинов при построении гистограммы.

Альтернативные правила

- **Правило Скотта:** $h = \frac{3.5\sigma}{n^{1/3}}$, где h — ширина бина, σ — стандартное отклонение
- **Правило Фридмана-Дьякониса:** $h = 2\frac{\text{IQR}}{n^{1/3}}$, где IQR — межквартильный размах
- **Правило квадратного корня:** $k = \sqrt{n}$ (самое простое, но менее точное)

Объём выборки n	**Правило Стёрджеса k**	**Правило квадратного корня k**
20	5	4
50	6	7
100	8	10
500	10	22
1000	11	32

Обоснование и ограничения

Правило Стёрджеса предполагает, что данные имеют приблизительно нормальное распределение. Для распределений с тяжёлыми хвостами или множеством мод оно может давать неоптимальные результаты.

Основные ограничения:

1. Лучше работает для распределений, близких к нормальному
2. При больших n может давать слишком много бинов
3. Не учитывает асимметрию распределения

Для нестандартных распределений рекомендуется:

- Использовать адаптивные методы (например, правило Фридмана-Дьякониса для данных с выбросами)

- Строить несколько гистограмм с разным числом бинов
- Использовать ядерные оценки плотности (KDE) как альтернативу гистограммам

Задание 1. *Измерено время загрузки страниц (в миллисекундах):*

```
[145, 132, 167, 189, 123, 156, 178, 145, 199, 165,
 134, 155, 177, 188, 143, 166, 154, 176, 199, 122]
```

Выполните следующие задания:

1. Рассчитайте все числовые характеристики: выборочное среднее, медиану, моду, выборочную дисперсию (смещенную и несмещенную), стандартное отклонение, размах, межквартильный размах.
2. Постройте гистограмму распределения, используя правило Стёрджеса для определения числа бинов.
3. Ответьте на вопросы:
   - Какая мера центра лучше описывает "типичное" время загрузки? Почему?
   - Как выбросы влияют на $\overline{x}$, медиану, S^2 и IQR?
   - Почему выбор числа бинов в гистограмме важен?

Эмпирическая функция распределения и её свойства

1. **Определение:**
   - **Эмпирическая функция распределения (ЭФР)** $F_n(x)$ для выборки $X_n = (x_1, ..., x_n)$:
   $$F_n(x) = \frac{\text{число элементов выборки} < x}{n} = P_n((-\infty, x))$$
   - Это выборочный аналог **теоретической функции распределения**
   $$F(x) = P(\xi < x)$$
   .
2. **Свойства ЭФР:**
   - $F_n(x) \in [0, 1]$
   - Неубывающая: если $x_1 < x_2$, то $F_n(x_1) \leq F_n(x_2)$
   - Непрерывна слева
   - $\lim_{x\to-\infty} F_n(x) = 0$, $\lim_{x\to+\infty} F_n(x) = 1$
   - Имеет скачки величиной $1/n$ в точках x_i (если все значения уникальны)
3. **Связь с вариационным рядом:**
   - Вариационный ряд: $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$
   - Тогда $F_n(x) = \frac{k}{n}$ для $x \in (X_{(k)}, X_{(k+1)}]$, где $X_{(0)} = -\infty$, $X_{(n+1)} = +\infty$
4. **Теорема Гливенко-Кантелли:**

Теорема 1 (Гливенко-Кантелли). *Пусть* $X_n = [X_\infty]_n \in F$. *Тогда при* $n \to \infty$

$$\sup_x |F_n(x) - F(x)| \xrightarrow{п.н.} 0.$$

Практический смысл: Для достаточно большой выборки эмпирическая функция распределения $F_n(x)$ становится сколь угодно близка к истинной $F(x)$.

Генерация выборки из нормального распределения, гистограмма, эмпирическая функция распределения.

Пример 1. Распределение хи-квадрат с k степенями свободы: сумма квадратов k независимых стандартных нормальных случайных величин

Построим три независимых выборки X, Y, Z объема 100 из стандартного нормального распределения и изобразим на общем графике эмпирическую функцию распределения X^2, $X^2 + Y^2$, $X^2 + Y^2 + Z^2$ и функции распределения хи-квадрат с $k = 1, 2, 3$ степенями свободы.

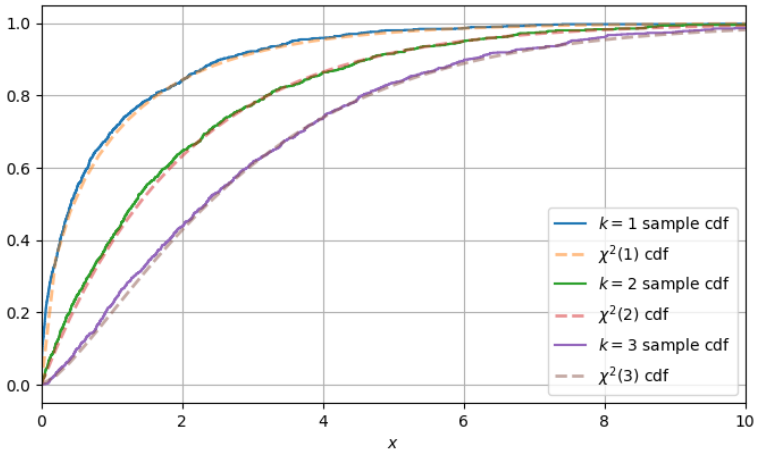

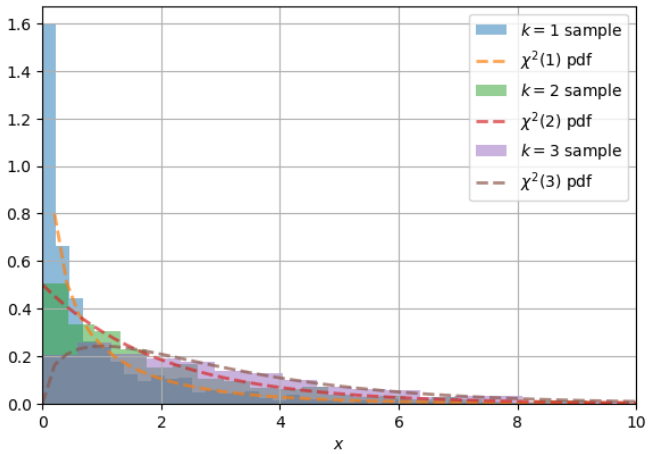

Пример 2. Распределение Стьюдента

Построим 11 независимых выборок X, $Y_{(k)}$, $k = 1, ..., 10$ объема 500 из стандартного нормального распределения и изобразим на общем графике эмпирическую функцию распределения

$$\frac{X}{\sqrt{Y_{(1)}^2}}, \quad \frac{X}{\sqrt{(Y_{(1)}^2 + Y_{(2)}^2)/2}}, \quad \frac{X}{\sqrt{(Y_{(1)}^2 + ... + Y_{(10)}^2)/10}}$$

и функции распределения Стьюдента с $k = 1, 2, 10$ степенями свободы.

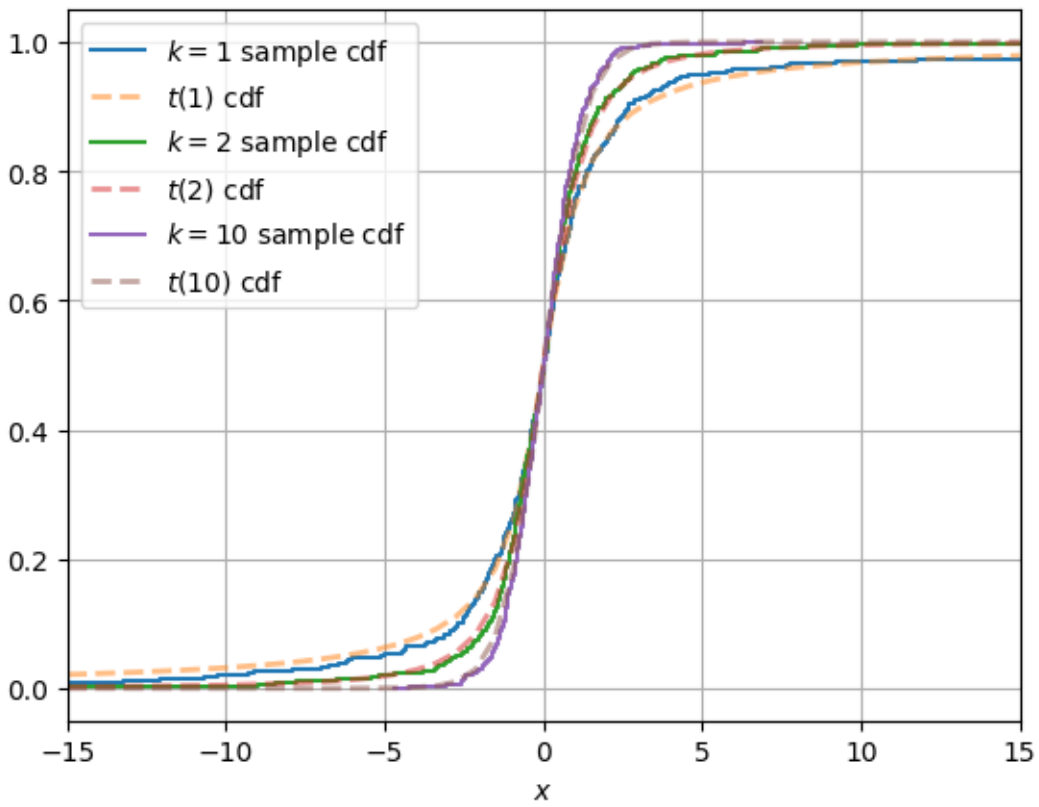

Пример 3. Распределение Фишера

Построим 30 независимых выборок $X_{(k)}$, $k = 1, ..., 10$, $Y_{(m)}$, $m = 1, ..., 20$ объема 1000 из стандартного нормального распределения и изобразим на общем графике эмпирическую функцию распределения

$$\frac{X_{(1)}^2}{Y_{(1)}^2}, \quad \frac{X_{(1)}^2}{(Y_{(1)}^2 + Y_{(2)}^2)/2}, \quad \frac{(X_{(1)}^2 + X_{(2)}^2)/2}{(Y_{(1)}^2 + Y_{(2)}^2)/2}, \quad \frac{(X_{(1)}^2 + ... + X_{(10)}^2)/10}{(Y_{(1)}^2 + ... + Y_{(20)}^2)/20}$$

и функции распределения Фишера с $(1, 1)$, $(1, 2)$, $(2, 2)$, $(10, 20)$ степенями свободы.

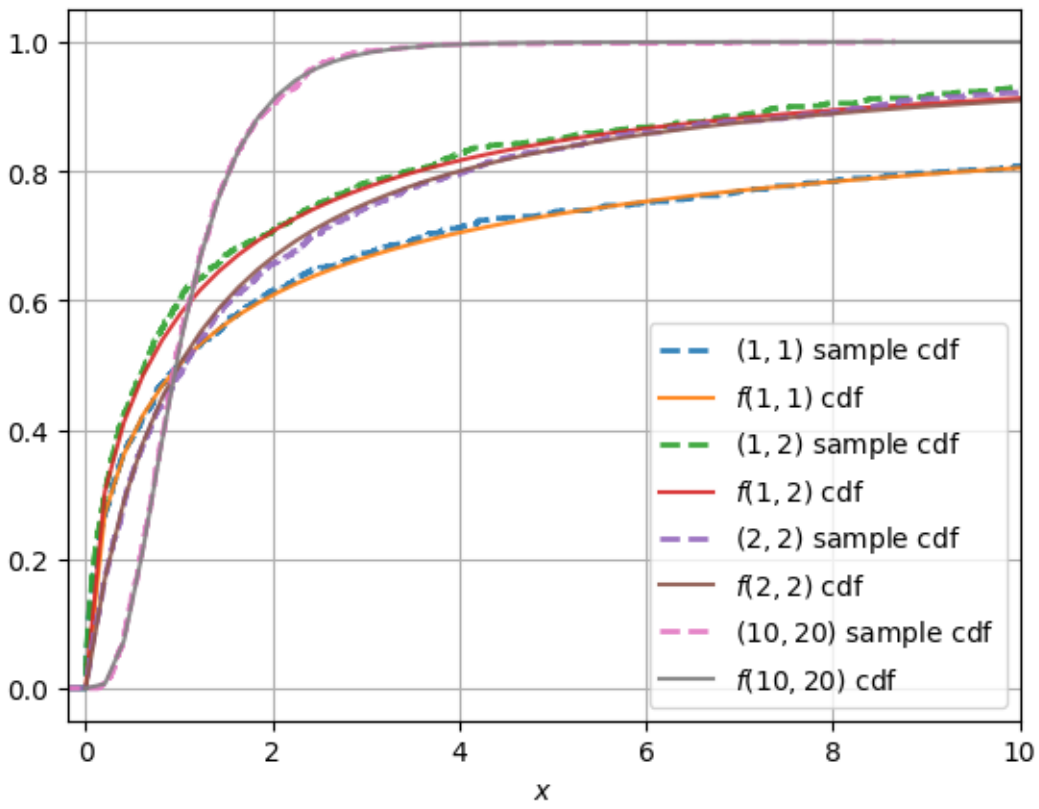

Пример 4. Связь между t и F распределениями

Построим три независимых выборки X, Y, Z объема 5000 из из распределения Стьюдента с $k = 2, 5, 10$ степенями свободы и изобразим на общем графике эмпирическую функцию распределения X^2, Y^2, Z^2 и функции распределения Фишера с $(1, k)$, $k = 2, 5, 10$, степенями свободы.

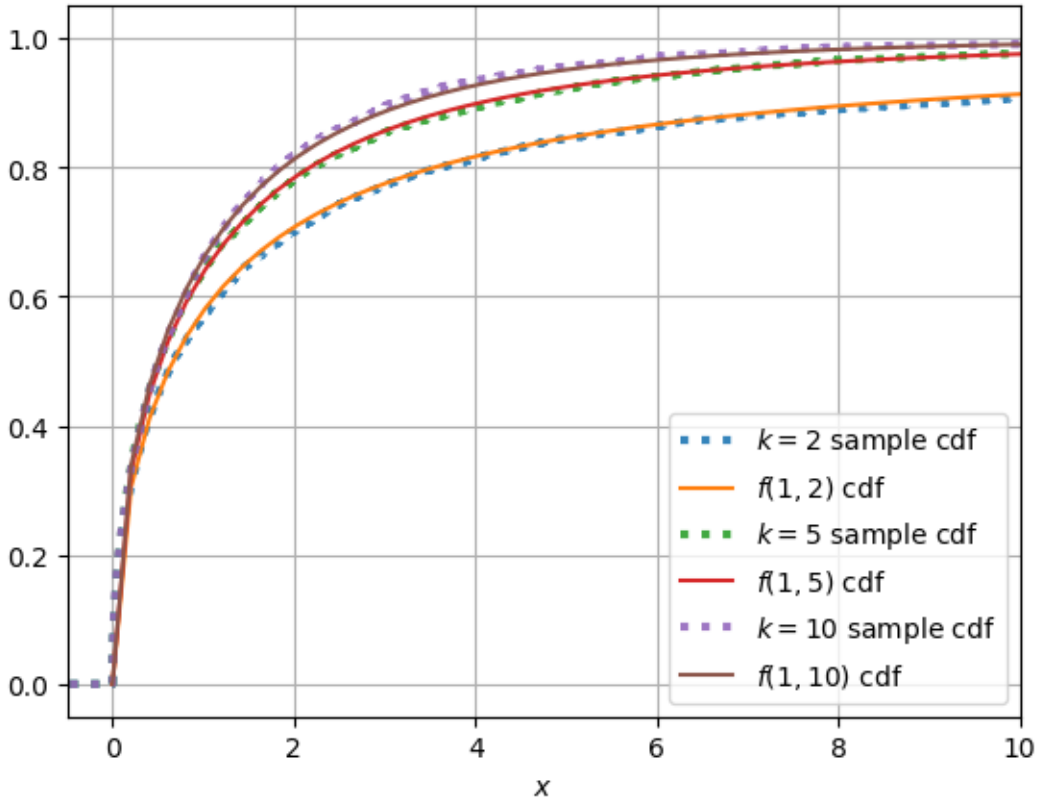

Пример 5.

Построим три независимых выборки X, Y, Z объема 100 из стандартного нормального распределения.

Вычислим среднее m и дисперсию S полученных выборок, для этого используем функцию scipy.stats.describe.

https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.describe.html

Из возвращаемых функцией значений нам понадобятся только mean и variance.

$$X: \text{ среднее } m = -0.10384651739409384, \text{ дисперсия } S = 0.8247698936301601$$
$$Y: \text{ среднее } m = 0.022304587049923885, \text{ дисперсия } S = 0.9094844970607499$$
$$Z: \text{ среднее } m = 0.06489625310044843, \text{ дисперсия } S = 1.1756693690387425$$

Пример 6.

Сгенерируем выборку $X_1, ..., X_n$ из стандартного нормального распределения. Для $n = 10$ построим эмпирическую функцию распределения F^*_{10}, изобразим ее на одном графике со стандартной нормальной функцией распределения.

При $n = 100, 1000, 10000$ вычислим **точное** значение статистики

$$D_n = \sup_{x \in \mathbb{R}} |F^*_n(x) - F(x)|.$$

Для посчёта точного значения воспользуемся тем, что F^*_n кусочно-постоянна, а F - непрерывно-монотонна. Это означает, что супремум достигается в точках разрыва(нужно проверить значение с обоих сторон точки) или в $\pm\inf$

$$n = 100, \ Dn = 0.144$$
$$n = 1000, \ Dn = 0.031$$
$$n = 10000, \ Dn = 0.007$$

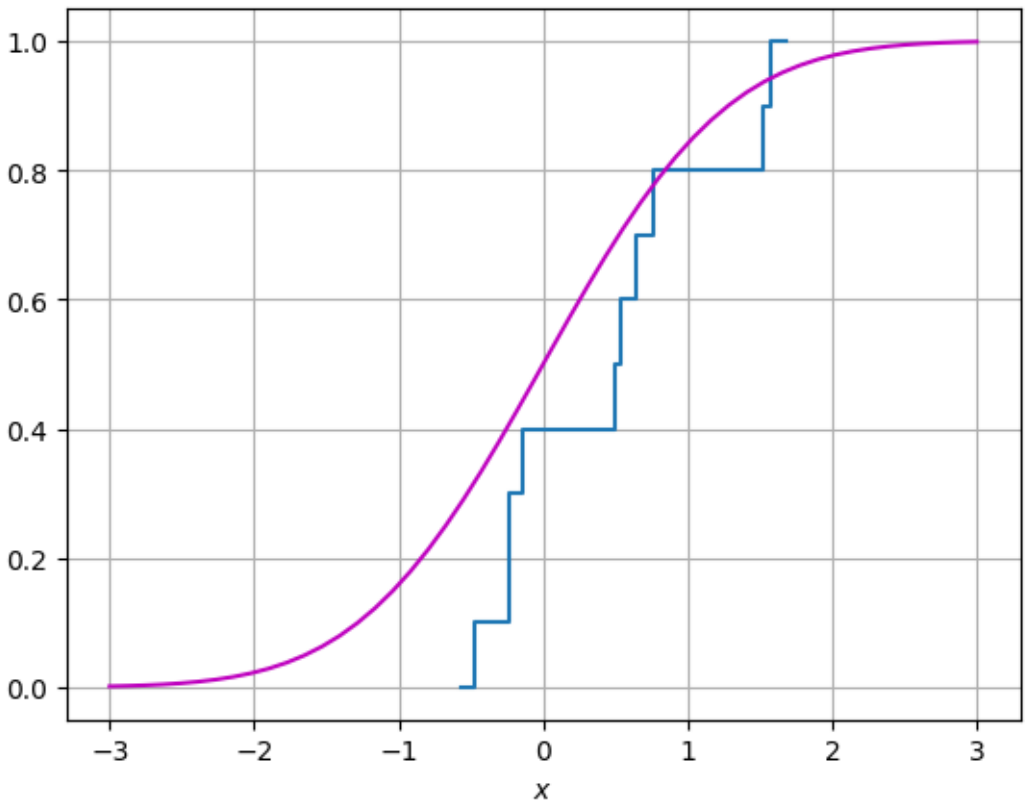

Задание 2. *Для значений времени загрузки страниц Задания 1:*

1. Постройте эмпирическую функцию распределения $F_n(x)$.
2. На том же графике постройте теоретическую функцию распределения для нормального распределения с параметрами $\mu = \overline{x}$, $\sigma = s$.
3. По графику $F_n(x)$ найдите:
   - Выборочную медиану (квантиль уровня $p = 0.5$)
   - Первый и третий квартили (Q_1 и Q_3)
   - Межквартильный размах (IQR)
4. Проверьте выполнение свойств ЭФР для вашей функции.
5. Ответьте на вопросы:
   - Согласуются ли данные с гипотезой о нормальном распределении?
   - Что происходит с "ступеньками"ЭФР при увеличении объема выборки?
   - Как теорема Гливенко-Кантелли связана с возможностью оценки вероятностей событий по выборке?

Для самостоятельной работы

Задание 3 (Задача оценки параметров)**.** *Пусть имеется выборка $X_n = (x_1, ..., x_n)$ из нормального распределения $N(\mu, \sigma^2)$ с неизвестными параметрами μ и σ^2.*

1. Предложите оценки для μ и σ^2 на основе выборочных характеристик.
2. Проверьте, являются ли ваши оценки несмещенными.
3. С помощью моделирования (генерируя выборки из $N(0, 1)$) убедитесь, что выборочное среднее $\overline{x}$ действительно сходится к μ при увеличении n.