

Лекция 9

Ковариация и коэффициент корреляции. Их свойства.

Опред. Ковариацией случайных величин X и Y называется число

$$\text{Cov}(X, Y) = M\{(X - MX)(Y - MY)\},$$

если математические ожидания справа существуют.

Правую часть последнего равенства можно преобразовать к виду $M\{XY\} - MX \cdot MY$, так что

$$\text{Cov}(X, Y) = M\{XY\} - MX \cdot MY.$$

Опред. Если $\text{Cov}(X, Y) = 0$, то СВ X и Y называются некоррелированными.

Заметим, что если X и Y — независимы, то они некоррелированы.

Непосредственно из определения следуют свойства ковариации:

1) $\text{Cov}(LX, Y) = \text{Cov}(X, LY) = L \cdot \text{Cov}(X, Y)$,
где L — постоянная;

2) $\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$;

3) $\text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$;

4) $\text{Cov}(X, X) = D\{X\}$, т.е. дисперсия формально может рассматриваться как ковариация между случайной величиной и ей самой.

Найдем дисперсию суммы двух произвольных СВ X и Y :

$$\begin{aligned} D\{X+Y\} &= M\{(X+Y - M\{X+Y\})^2\} = \\ &= M\{((X-MX) + (Y-MY))^2\} = \\ &= M\{(X-MX)^2\} + M\{(Y-MY)^2\} + 2M\{(X-MX)(Y-MY)\} = \\ &= DX + DY + 2\text{Cov}(X, Y). \end{aligned}$$

В случае суммы n случайных величин аналогично устанавливается, что

$$D\{X_1 + X_2 + \dots + X_n\} = \sum_{i=1}^n DX_i + 2 \sum_{i < j} \text{Cov}(X_i, X_j).$$

В частности, если все дисперсии DX_i и ~~коэффициенты~~ ковариации $\text{Cov}(X_i, X_j)$ одинаковы:

$$DX_i = d \quad \forall i=1, \dots, n, \quad \text{Cov}(X_i, X_j) = K \quad \forall i \neq j,$$

то

$$D\{X_1 + X_2 + \dots + X_n\} = n \cdot d + n(n-1)K.$$

Опрег. Коэффициентом корреляции случайных величин X и Y называется число

$$\tau_{xy} = \frac{\text{Cov}(X, Y)}{\sigma_x \sigma_y},$$

где $\sigma_x^2 = DX$, $\sigma_y^2 = DY$. (τ_{xy} определен только при $\sigma_x > 0$ и $\sigma_y > 0$.)

Утверждение. $|\tau_{xy}| \leq 1$.

Док-во;

$$D\{X+Y\} = DX + DY + 2\tau_{xy}\sqrt{DX}\sqrt{DY},$$

откуда

-3-

$$\frac{D\{X+Y\}}{\sqrt{DX}\sqrt{DY}} = \frac{\sqrt{DX}}{\sqrt{DY}} + \frac{\sqrt{DY}}{\sqrt{DX}} + 2r_{xy} \quad (*)$$

Положим $t = \frac{\sqrt{DX}}{\sqrt{DY}} \in (0; +\infty)$. Из (*) следует,
что каково бы ни было $t \in (0; +\infty)$

$$t + \frac{1}{t} + 2r_{xy} \geq 0$$

или

$$r_{xy} \geq -\frac{1}{2} \left(t + \frac{1}{t} \right) \quad \forall t \in (0; +\infty),$$

так что

$$r_{xy} \geq \max_{t \in (0; +\infty)} \left\{ -\frac{1}{2} \left(t + \frac{1}{t} \right) \right\} = -1.$$

Далее

$$D\{X-Y\} = DX + DY - 2r_{xy}\sqrt{DX}\sqrt{DY}$$

$$\frac{D\{X-Y\}}{\sqrt{DX}\sqrt{DY}} = \frac{\sqrt{DX}}{\sqrt{DY}} + \frac{\sqrt{DY}}{\sqrt{DX}} - 2r_{xy} \quad (**)$$

Положим $t = \frac{\sqrt{DX}}{\sqrt{DY}} \in (0; +\infty)$. Из (**) следует

$$t + \frac{1}{t} - 2r_{xy} \geq 0$$

или

$$r_{xy} \leq \frac{1}{2} \left(t + \frac{1}{t} \right) \quad \forall t \in (0; +\infty),$$

так что

$$r_{xy} \leq \min_{t \in (0; +\infty)} \left\{ \frac{1}{2} \left(t + \frac{1}{t} \right) \right\} = 1.$$

Итак, мы имеем следующие свойства коэффициента корреляции:

1) r_{xy} — безразмерная величина;

- 2) Если СВ X и Y связаны линейной зависимостью

$$Y = \alpha X + \beta,$$

где $\alpha \neq 0$, β — произвольные постоянные, то

$$r_{xy} = 1 \text{ при } \alpha > 0;$$

$$r_{xy} = -1 \text{ при } \alpha < 0.$$

- 3) Если X и Y независимые СВ, то $r_{xy} = 0$.

На содержательном уровне величина коэффициента r_{xy} характеризует тесноту связи между СВ X и Y : чем меньше $|r_{xy}|$, тем эта связь слабее. При этом знак r_{xy} допускает следующую интерпретацию: отрицательные значения r_{xy} означают, как правило, что ^{в среднем} увеличение Y соответствует уменьшению X и, наоборот, уменьшению Y соответствует увеличение X (такое положение вещей иногда характеризуют словами « X и Y изменяются в противофазе»); положительные значения r_{xy} означают, как правило, что в среднем увеличению Y соответствует увеличение и X , а уменьшению Y соответствует и уменьшение X (« X и Y изменяются в фазе, или синфазно»).

- 4) Из некоррелированности случайных величин, вообще говоря, не следует их независимость.

Покажем это на примере. Пусть X — центрированная (т.е. $MX=0$) нормально распределенная случайная величина:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}, \quad x \in (-\infty; +\infty)$$

Пусть $Y = X^2$. Тогда

$$\begin{aligned} \text{Cov}(X, Y) &= M\{XY\} - MX \cdot MY = \\ &= M\{X^3\} - 0 \cdot MY = \underbrace{\int_{-\infty}^{+\infty} x^3 \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} dx}_{\text{интеграл от нечетной функции по симметричному промежутку}} = 0, \end{aligned}$$

так что и $\tau_{xy} = 0$.

Однако СВ X и Y , очевидно, не являющиеся независимыми. Покажем это формально, т.е. покажем, что

$$P\{X < x, Y < y\} \neq P\{X < x\} \cdot P\{Y < y\}.$$

Обозначим через $F(x)$ функцию распределения СВ X . Пусть даны определенные $x > 0, y > 0, x < \sqrt{y}$. Тогда

$$\begin{aligned} P\{X < x, Y < y\} &= P\{X < x, X^2 < y\} = P\{X < x, -\sqrt{y} < X < \sqrt{y}\} = \\ &= P\{-\sqrt{y} < X < x\} = F(x) - F(-\sqrt{y}), \quad (1) \end{aligned}$$

$$\begin{aligned} P\{X < x\} \cdot P\{Y < y\} &= F(x) \cdot P\{X^2 < y\} = F(x) \cdot P\{-\sqrt{y} < X < \sqrt{y}\} = \\ &= F(x) \cdot (F(\sqrt{y}) - F(-\sqrt{y})). \quad (2) \end{aligned}$$

А так, что (1) и (2) не совпадают, т.е. СВ X и Y не являются независимыми.

5) Отметим также, что известная связь между СВ X и Y (когда по реализации одной СВ можно однозначно определить реализацию другой СВ, что, например, имеет место, когда X и Y связаны функциональной зависимостью: $Y = \varphi(X)$, где $\varphi(\dots)$ - заданная функция) далеко не всегда означает, что $|\tau_{xy}| = 1$; более того, в этом случае $|\tau_{xy}|$ может значительно отличаться от 1 (и даже быть нулем!)

Приведем пример. Пусть СВ X имеет плотность

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma_x} e^{-\frac{x^2}{2\sigma_x^2}}, \quad x \in (-\infty; +\infty),$$

а СВ $Y = X^{2k-1}$, $k = 2, 3, \dots$. Найдём τ_{xy} .
Имеем

$$\begin{aligned} \text{Cov}(X, Y) &= M\{XY\} - MX \cdot MY = M\{X \cdot X^{2k-1}\} - 0 = \\ &= M\{X^{2k}\} = \\ &= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma_x} x^{2k} e^{-\frac{x^2}{2\sigma_x^2}} dx = \left\{ \begin{array}{l} \text{замена:} \\ t = \frac{x}{\sigma_x} \end{array} \right\} = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \sigma_x^{2k} t^{2k} e^{-\frac{t^2}{2}} dt = \\ &= \frac{\sigma_x^{2k}}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} t^{2k-1} d\left(e^{-\frac{t^2}{2}}\right) = \frac{\sigma_x^{2k}}{\sqrt{2\pi}} \left\{ -t^{2k-1} e^{-\frac{t^2}{2}} \Big|_{-\infty}^{+\infty} + \int_{-\infty}^{+\infty} (2k-1) t^{2k-2} e^{-\frac{t^2}{2}} dt \right\} \\ &= \frac{\sigma_x^{2k}}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} (2k-1) t^{2k-2} e^{-\frac{t^2}{2}} dt. \end{aligned}$$

Если введём обозначение

$$J_{2k} = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} t^{2k} e^{-\frac{t^2}{2}} dt,$$

то

$$J_{2k} = (2k-1) \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} t^{2k-2} e^{-\frac{t^2}{2}} dt = (2k-1) J_{2k-2},$$

т.е.

$$J_{2k} = (2k-1) J_{2k-2} = (2k-1)(2k-3) J_{2k-4} =$$

$$= \dots = (2k-1)(2k-3) \dots (2k-(2k-1)) J_0 =$$

$$= (2k-1)!! \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = (2k-1)!! ,$$

Далее,

$$\text{так что } M\{X^{2k}\} = \sigma_x^{2k} \cdot (2k-1)!! \quad (*)$$

$$\begin{aligned} \sigma_y^2 &= D\{Y\} = M\{Y^2\} - (MY)^2 = M\{X^{4k-2}\} - (M\{X^{2k-1}\})^2 = \\ &= M\{X^{4k-2}\} = \sigma_x^{4k-2} \cdot (4k-3)!! \end{aligned}$$

↑
по аналогии
с предыдущим
мамом (*)

Таким образом,

$$\begin{aligned} r_{xy} &= \frac{\text{Cov}(X, Y)}{\sigma_x \sigma_y} = \frac{M\{X^{2k}\}}{\sigma_x \sqrt{M\{X^{4k-2}\}}} = \\ &= \frac{\sigma_x^{2k} \cdot (2k-1)!!}{\sigma_x \cdot \sigma_x^{2k-1} \sqrt{(4k-3)!!}} = \frac{(2k-1)!!}{\sqrt{(4k-3)!!}} \end{aligned}$$

Пусть $k=2$ получим

$$r_{xy} = \frac{3!!}{\sqrt{5!!}} = \frac{3}{\sqrt{15}} \approx 0,774.$$

Пусть $k=3$ получим

$$r_{xy} = \frac{5!!}{\sqrt{9!!}} = \frac{3 \cdot 5}{\sqrt{9 \cdot 7 \cdot 5 \cdot 3}} = \frac{5}{\sqrt{105}} \approx 0,487.$$